Google Cloud

生成式 AI：全面了解生成式 AI

恭喜您完成了生成式 AI 领导者学习路线的第三门课程。您可以通过本课程总结回顾所学内容。建议您打印下来，方便在日后作为生成式 AI 方面的参考。

在开始生成式 AI 项目之前，需要考虑以下事项：

需求：

- **规模**：用户量级
- **定制化**：AI 的专精程度
- **用户互动**：用户的互动方式
- **隐私**：数据的敏感程度
- **延迟时间**：响应时间
- **连接性**：系统连接情况

资源：

- **人力**：获取 AI 专业知识的能力
- **资金**：预算情况
- **时间**：项目时间规划

平台：构建和扩展 AI 项目的基础。

Vertex AI：Google Cloud 的统一机器学习 (ML) 平台，帮助简化整个机器学习工作流。Vertex AI 提供构建、部署和管理机器学习与生成式 AI 解决方案所需的基础设施、工具和预训练模型。

基础设施：一切的基础，提供生成式 AI 所需的核心计算资源，包括物理硬件（如服务器、GPU 和 TPU），以及训练、存储和运行 AI 模型所需的必要软件。

边缘 AI：在数据创建位置附近的基础设施（设备或服务器）上运行 AI 解决方案。

Google 提供 **Lite Runtime (LiteRT)** 等工具，帮助开发者在边缘设备上部署 AI 模型。

Gemini Nano 是面向终端设备优化的高能效轻量化 AI 模型。

生成式 AI 架构

- 生成式 AI 赋能的应用
- 智能体
- 平台
- 模型
- 基础设施

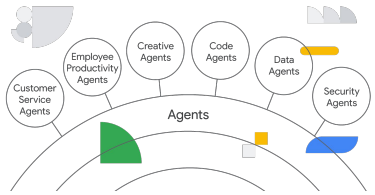

智能体：智能体是一种通过**观察**世界并使用工具**采取行动**，以实现**目标**的生成式 AI 应用。

其运作机制包括：

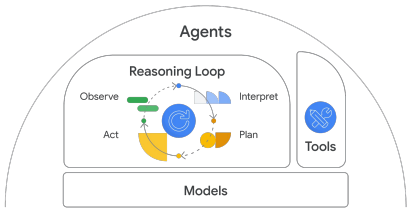

- **推理循环**：智能体执行观察、解释、推理和行动的闭环过程，通常会使用提示工程。
- **工具**：允许智能体与环境互动的各种功能，例如数据访问和处理，或软件或硬件互动。
- **模型**：AI 系统的核心，由各种算法组成，这些算法可以从数据中学习规律模式，并进行预测或生成新内容。

Vertex AI 为您提供了多种处理项目 AI 模型的方案。

- **Model Garden**：选择现有的 Google、第三方或开源模型。
- **Model Builder**：训练和使用您自己的模型。完全自定义，使用机器学习框架大规模创建和训练模型。或者，使用 AutoML，只需极少的技术知识和操作步骤即可创建和训练模型。